Marketplace Safety

Ali – Operations Manager

"Vi drunknar i flaggningar"

Grupp 3:

Hamed Rezai

Jazdan Tabrizi

Martin Westberg

Mål: Arbetslista:

- *Pricksäker*
- *Lagom lång*

Dataöversikt

historic_data.csv: 12,000 rader

17 features, 1 target (is_suspicious, 0/1)

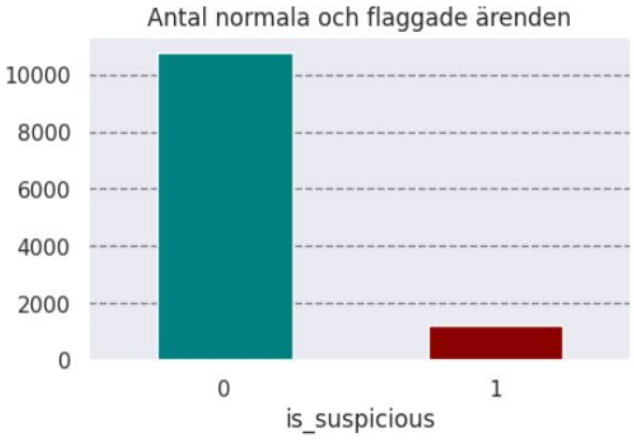

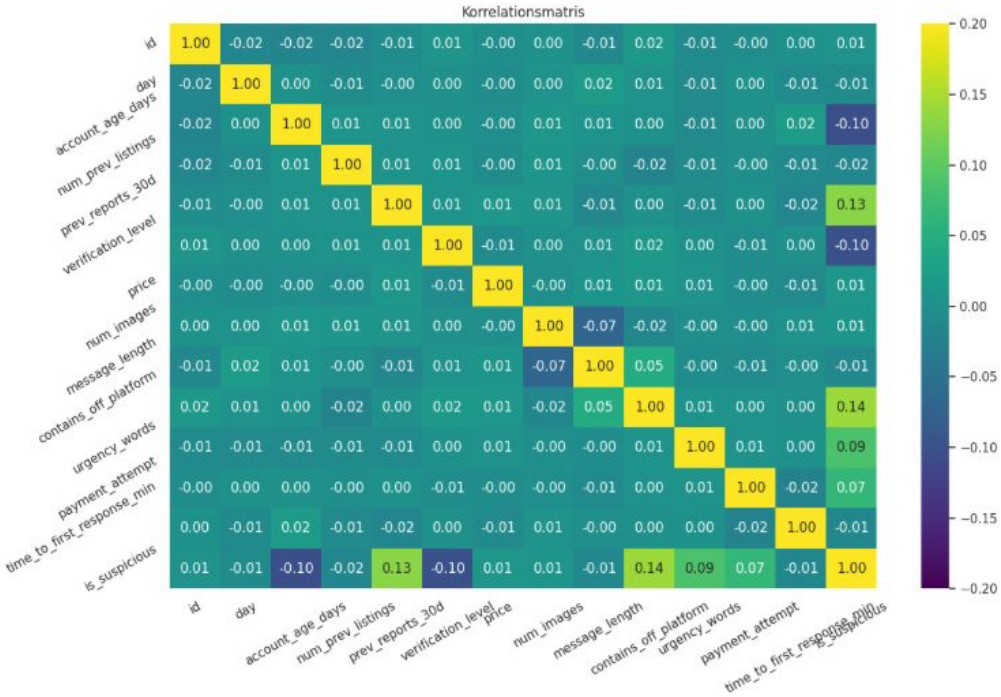

Train/test & Pipeline

<u>Split:</u>

- train: 80%, test: 20% (med stratify).

<u>Pipeline:</u>

- Preprocess (impute median, *OHE* most frequent) -> modell.

- Select dtypes delar upp kategori & nummer-kolumner.
- Funktion *align_to_scema* skapar NaN kolumner och ger rätt ordning.

Cross Validation

Modeller:

- 5 modeller jämfördes med 5-fold stratified cross validation
- Precision prioriterades för att undvika falska alarm
- Logistic Regression gav högst precision och valdes
- Modellen är försiktig: hög precision men låg recall

	Model	Precision_mean	Precision_std	Recall	F1	ROC_AUC
1	Logistic Regression	0.5843	0.1323	0.0439	0.0814	0.7384
4	Gradient Boosting	0.5315	0.0260	0.0705	0.1243	0.7558
3	Random Forest	0.4557	0.1164	0.0092	0.0180	0.7326
2	Decision Tree	0.1832	0.0171	0.2124	0.1966	0.5525
0	Baseline	0.0000	0.0000	0.0000	0.0000	0.5000

Optimering

<u>Hyperparametrar som optimeras:</u>

- Komplexitet: *C=0.01* (mer enkel: mindre overfit),
- Klassvikt: *None* (90/10 är inte extremt),
- Bromsning: *L2* (coeffs inte → 0 helt; brus övertolkas ej),
- Solver: *liblinear* (optimerad för binärt).

```
Optimerade hyperparametrar:
{'model__C': 0.01, 'model__class_weight': None, 'model__penalty': 'l2', 'model__solver': 'liblinear'}

Högsta Precision enl. CV: 0.6746
```

<u>Resultat:</u> 58% → 67.5% *precision*.

Logistic Regression & Top-5%

Test–data:

```
Precision: 0.625
Recall: 0.0204
F1: 0.0395
ROC-AUC: 0.7356

Förvirringsmatris:
[[2152    3]
 [ 240    5]]
```

Top–5%

```
Fövirringsmatris för top-5%:
 [[2084   71]
 [ 204   41]]
```

y_test hade 2,400 rader över 14 dagar → 8-9 ärenden/dag

Resultat: *new_data.csv*

- 2000 rader över 5 dagar.
- Joblib: sparad pipeline, sen top-5%.
- Utan label: ingen förvirringsmatris / *precision*,
- Vi tar fram prioriterade ärenden (se radnummer).
- Rader i prio-lista: 97, ca 20 ärenden om dagen.
- Skrivs ut CSV fil till *operations*-teamet.

	id	day	event_type	category	region	device	account_age_days	num_prev_listings	prev_reports_30d	verification_level	...	message_length	contains_off_platform	urgency_words	payment_attempt	time_to_first_response_min	predicted_target	y_proba	daily_ranking	top5perc_per_day	top5perc_flag
1130	1130	1	ad_post	phones	urban	android	23.5	3	2	1	...	229	1	0	0	5.2	1	0.561484	1.0	19	True
207	207	1	ad_post	electronics	rural	android	9.7	6	0	0	...	179	1	0	1	1.1	0	0.432830	2.0	19	True
126	126	1	message_send	furniture	urban	ios	38.3	2	2	1	...	128	0	0	1	22.9	0	0.401438	3.0	19	True
1025	1025	1	message_send	electronics	urban	ios	50.5	3	1	0	...	150	0	1	0	26.8	0	0.376222	4.0	19	True
527	527	1	ad_post	bikes	urban	android	44.6	0	1	1	...	163	0	1	1	15.5	0	0.341050	5.0	19	True
1169	1169	1	message_send	bikes	urban	ios	106.1	3	2	0	...	202	0	0	0	89.6	0	0.324438	6.0	19	True
1917	1917	1	ad_post	bikes	rural	android	6.4	5	0	0	...	157	0	1	1	15.2	0	0.320912	7.0	19	True
1409	1409	1	message_send	other	urban	android	9.2	4	0	0	...	96	0	1	1	4.8	0	0.318594	8.0	19	True
1462	1462	1	ad_post	electronics	rural	ios	73.5	2	0	0	...	87	1	0	0	14.6	0	0.312522	9.0	19	True
1495	1495	1	ad_post	fashion	urban	android	23.9	2	0	1	...	0	1	0	1	NaN	0	0.311296	10.0	19	True

Risker & Nästa steg

- Missar många verkligt misstänkta fall
- Obalanserad data försvårar klassificeringen
- Svaga samband i flera variabler
- Top-5 % är praktiskt men kan missa risk utanför urvalet
- Utveckla fler features
- Testa fler modeller
- Följa upp på ny data
- Mäta faktisk affärsnytta i drift